# 一、项目目标

本项目用于自动采集“上海市政府采购网”中的采购公告信息，并整理为结构化 Excel 数据，用于投标筛选、项目跟进及信息分析。

采集内容包括：

- 公告日期
- 报名时间（获取采购文件时间 ）
- 投标截止时间
- 项目名称
- 预算金额
- 投标要求（申请人的资格要求）
- 采购人/代理机构及联系方式
- 详情页链接

并支持对项目进行筛选分类（如弱电工程）。

---

# 二、系统整体流程

程序分为两大阶段：

## 1️⃣ 列表获取（接口方式）

通过网站接口直接获取公告列表：

- 接口地址：`/portal/category`
- 关键参数：`categoryCode = ZcyAnnouncement2`

⚠️ 注意：

- `ZcyAnnouncement` → 采购意向页面
- `ZcyAnnouncement2` → 采购公告页面

该阶段负责：

- 获取项目名称
- 获取公告日期
- 拼接详情页 URL

---

## 2️⃣ 详情解析（浏览器方式）

详情页信息不在接口中，而在网页 iframe 中：

页面A（外层）
↓
iframe
↓
页面B（正文）

因此必须：

- 打开详情页
- 进入 iframe
- 提取正文文本
- 再用规则解析字段

---

# 三、筛选机制说明（重要）

当前已实现关键词筛选机制，用于筛选特定类型项目（如弱电工程）。

## 当前实现方式：

- 基于项目名称进行关键词匹配
- 命中即保留

## 已使用示例：

弱电工程关键词（安防、监控、门禁、网络、机房等）

---

## 推荐后续扩展方案：

为了提高准确率，建议逐步升级为：

1. 关键词分组标签
    - 弱电 / 信息化 / 机房 / 安防
2. 正则匹配
    - 捕捉更规范术语
3. 排除词机制
    - 过滤无关项目（如“保洁”“绿化”）
4. 多字段匹配
    - 项目名称 + 正文 + 类目联合判断
5. 评分机制
    - 命中多个关键词才通过
6. **AI**分类（后续）
    - 用模型对项目做语义分类

---

## 四、日期控制机制

当前支持自定义日期区间：

START_DATE = "2026-03-21"
END_DATE = "2026-03-29"

每次运行前可手动修改。

⚠️ 不建议写死日期，否则会导致数据失效。

---

## 五、关键工程设计说明

### 1️⃣ 为什么不用网页点击？

因为：

- 页面是动态加载
- 左侧菜单点击不会刷新 URL（如果你有办法克服这个问题，网页点击值得一试）

👉 使用接口更稳定、更快

---

### 2️⃣ 为什么必须用 iframe？

因为：

- 详情正文不在主 DOM 中
- 不进入 iframe 会导致抓不到数据

---

### 3️⃣ 为什么要加 sleep？

用途不是“凑时间”，而是：

- 防止访问过快触发反爬
- 等待 iframe 内容加载完成
- 提高抓取成功率

👉 属于“节流与稳定性控制”

---

### 4️⃣ 为什么有些字段用正则提取？

因为：

- 页面没有统一结构（不是标准 JSON）
- 信息嵌在自然语言中

例如：

三、获取采购文件
时间：2026年3月20日至2026年3月25日

👉 只能通过文本匹配提取

---

# 六、已知问题与限制

## ⚠️ 1. AI token 限制（用稳定的代码+模型修改细节 ）

我是用的 claude code api 和 KIMI 2.5K 接入openclaw
豆包seed 2.0 code 接入 cursor

当前 KIMI效果最佳，尽量不要相信任何销售卖的api套餐，没有官方销售，说官方销售的都是骗子，建议直接去官方网站充值拿接口最可靠，他们销售是拿了代理权，他们对自己接口的传输流和协议版本都没有任何保障的，需要花大量时间来做适配工作。

当前api遇到的主要困难：

- 信息获取过程中，可能被截断（只能取到部分）

原因：

- 单次模型调用长度限制

解决方案：

- 分段提取 → 多次调用 → 拼接结果（这个我还没做）
- 或使用更大的模型（提高成本）/ 0-token方案

---

## ⚠️ 2. 联系方式提取不完全

原因：

- 页面格式不统一

建议：

- 后续增强规则匹配
- 或单独针对该模块优化

---

### ⚠️ 3. Excel 文件写入失败

原因：

- 文件被打开，关闭旧的excel即可
- 或生成 `加角标版本.xlsx`
- 防止在别人电脑上跑，出了问题来骂人

---

### ⚠️ 4. 本地路径问题

部分脚本可能写死路径（如 `/Users/...`）

建议：

- 直接在当前路径
- 或直接在桌面位置生成文件夹，内容生成在文件夹里

---

## 七、代码结构说明（后续工作直接用这个就好了）

核心模块：

| 模块 | 功能 |
| --- | --- |
| fetch_list_page | 调用接口 |
| extract_list_items | 解析列表 |
| enrich_items | 获取详情页 |
| extract_* | 字段提取 |
| filter_logic | 项目筛选 |
| export_excel | 输出 |

---

## 八、输出数据结构

## （我写的需求文档里更详细，对照excel看）

| 列名 | 含义 |
| --- | --- |
| 序号 | 自动编号 |
| 网站名 | 上海市政府采购网 |
| 公告日期 | 列表获取 |
| 报名日期 | 获取采购文件时间 |
| 投标截止日期 | 截止时间 |
| 项目名称 | 项目标题 |
| 预算 | 预算金额 |
| 投标要求 | 完整资格要求 |
| 采购人/代理机构及联系方法 | 联系方式 |
| 具体信息 | 详情URL |

---

# 九、关于openclaw

1. 我是用的kimi 2.5 的**Allegro**套餐（自费），官方介绍说api额度给了10倍，但效果一般，还是建议代码自己vibe coding（我用的claude code）然后再交给agent做自动化。
2. 飞书这边直接开通所有权限给龙虾即可，我们跑的数据都是政府公开信息，就算数据外漏也对公司没有损失。当前龙虾使用kimi2.5模型 自动发送每日报告和excel没有问题，公司采购的豆包api无法使用（跟销售买的）协议版本跟龙虾官方对应不上，转接cursor可以使用api，再调用数据给skill发送自动报告，建议发邮件，但工程流程比较繁琐，个人认为没必要，尤其老板这边着急要成品。

# 十、后续优化建议

建议优先级：

### ⭐ 高优先级

- 筛选机制升级（避免误判）
- 联系方式提取优化
- 自动每日运行（定时任务）
- 数据去重与增量更新

⭐⭐⭐ 长期

- 接入数据库
- 做项目推荐/提醒系统
- AI分类与摘要